

SISTEMA DE SUGESTÃO DE INVESTIMENTOS UTILIZANDO MACHINE LEARNING E ANÁLISE DE SENTIMENTO DE NOTÍCIAS

Gabriel Sales Costa

Igor Masson Calille

Lucas Costa Pessoa Graziano

Pedro Alcantara Krivochein

Orientador: Flávio Morgado

Introdução

Guida (2019, p. 185) chama a atenção para o fato de que “à medida que a tecnologia avança e os participantes do mercado se tornam mais conectados, o volume e a frequência das notícias crescem progressivamente mais rápido”. Em vista disso, com um crescente volume de dados e rápida disseminação de notícias e informações, os investidores acabam tendo dificuldades para filtrar e interpretar com precisão dados de fontes múltiplas, e como podem criar tendências em seus investimentos. Nesse sentido, “incorporar uma ideia de investimento numa estratégia algorítmica da vida real implica um significativo risco que requer uma abordagem científica” (Jansen, 2020, p. 15), pois a notícia é considerada um ‘evento informativo’ macro que influencia o mercado de microestrutura, impactando a formação de preços, a volatilidade e a liquidez de um determinado ativo (MITRA, 2015)

Nesse universo, a utilização de técnicas avançadas de *Machine learning* (ML), levam a vantagens contra abordagens não algorítmicas porque “oferecem um forte foco em dados empíricos em grande escala, transformados e analisados em uma escala nunca vista antes para obter detalhes de padrões que eram indetectáveis à inspeção anterior” (GUIDA, 2019, pg. 1). Eles permitem que os investidores identifiquem padrões, tendências e correlações nos dados, já que separam a análise precisa de ruídos que não possuem uma conversão a um padrão, permitindo uma avaliação mais precisa e em tempo real do mercado financeiro. De acordo com o Marcos López de Prado (2020), a tendência de utilizar *Machine learning* na área de finanças está em um crescimento progressivo, devido ao surgimento do conceito do *Big Data*, com conjunto de dados cada vez maiores e mais complexos, e com computadores cada vez mais eficientes, todos os algoritmos conspiram para desencadear uma era de ouro do *Machine learning* financeiro.

Gu *et al.* (2018) e seus colaboradores, empregando técnicas de *Machine learning*, investigaram se o mercado de ações apresenta uma previsibilidade. Eles forneceram um conjunto de indicadores de comparação para a precisão preditiva de métodos de aprendizado e depois demonstraram os ganhos econômicos para os investidores de ações com essas técnicas.

Tendo em vista tais resultados obtidos por Gu *et al.* (2018), serão abordadas técnicas de finanças quantitativas e modelos de inteligência artificial, ao combinar análise preditiva com informações de notícias em tempo real, busca-se oferecer uma abordagem automatizada para a sugestão da tomada de decisão de investimento em ações, capacitando os investidores para reagir de forma rápida e eficaz às mudanças no mercado. Essa abordagem tem o potencial de oferecer estratégias para o melhorar desempenho dos investimentos, e capacitar investidores a alcançarem seus objetivos financeiros.

A busca por previsões financeiras desempenha um papel essencial em estratégias de investimento e na gestão de riscos. No ambiente volátil do mercado financeiro os métodos tradicionais de previsão enfrentam desafios significativos devido ao aumento na quantidade e complexidade dos dados, por isso “as técnicas de ML são projetadas para analisar grande volume de dados (Big Data), e é, por isso, que são frequentemente citados juntos” (López DE PRADO, 2020, p.17). López de Prado (2019) também comentou que métodos convencionais, como a econometria, muitas vezes falham em abordar a complexidade dos conjuntos de dados, como os não numéricos e não categóricos, resultando frequentemente em previsões imprecisas. Também, a crescente disponibilidade de dados não estruturados, como notícias e relatórios financeiros, requer métodos de preparação únicos e alta força computacional para realizar as tarefas de mineração necessárias (BALAJI, 2020).

Desse modo, o ML surge como uma ferramenta importante, capaz de analisar grandes volumes de dados e identificar padrões complexos que podem prever movimentos do mercado com maior precisão. López de Prado (2020, p.18) defende que “os modelos de ML podem ajudar a melhorar o desempenho do investimento, encontrando o volume e tempo adequado de uma posição de compra ou venda”.

Impacto para Stakeholders

Uma das aplicações mais notáveis de inovação no setor financeiro é a previsão de preços de ativos por meio de modelos de *Machine Learning* e de análise de sentimento em notícias. López de Prado (2020, p.18) menciona em seu livro, “além da previsão de preços, existem outras verdades fundamentais e aplicações

criticamente importantes que estão moldando o futuro das finanças, tais como análise de sentimento, construção de carteira e detecção de valores discrepantes”.

Este artigo analisa estas principais aplicações de ML no setor financeiro, buscando melhorar a precisão com que se pode prever o desempenho do mercado. A aplicação de ML ajudará qualquer usuário que dependa de dados precisos e atualizados para poder tomar decisões informadas sobre compra e venda de ativos, por meio de recomendações de investimento e carteiras personalizadas.

Objetivos

Objetivo Geral

Auxiliar os investidores com uma ferramenta que utilize aprendizado de máquina e processamento de linguagem natural (NLP) em análise de sentimento de notícias, para sugestão da tomada de decisão da compra ou venda de uma ação, tendo em vista a tendência do mercado analisada pelos modelos.

Objetivos Específicos

- Implementar um modelo de LLM para a análise de sentimento de notícia: realizar um fine-tuning de um modelo de *Large Language Model* (LLM), empregando técnicas de processamento de linguagem natural (PLN) e análise de sentimento em notícias, visando prever tendências do valor de ações no mercado financeiro.
- Implementar um modelo de machine learning para a previsão do valor das ações: desenvolver um modelo de machine learning, empregando técnicas de algoritmos de regressão supervisionada, com o intuito de prever movimentações geradas exclusivamente pelos dados das ações, como valor de abertura, fechamento, alta do período e baixa do período.
- Avaliar a precisão e eficácia do modelo, comparando os resultados com métodos tradicionais de análise do mercado financeiro, com intuito de apresentar suas vantagens e identificar possíveis limitações.

Revisão da literatura

Modelos Preditivos

Em um ambiente de mercado financeiro caracterizado por volatilidade e mudanças rápidas, López de Prado (2020) destaca que a eficácia dos modelos preditivos se torna um fator decisivo para o sucesso das estratégias de negociação algorítmica. Modelos em especial como redes neurais profundas como as *Large Language Models* (LLM), “*Large Language Models*, como GPT-3, demonstraram ser excelentes na resolução de tarefas com dados limitados. A razão é que esses modelos aprendem representações úteis de texto que codifica informações em muitas dimensões, como sentimento, tópico, estrutura de texto e muito mais.” (Tunstall, 2022, p.275) acabam tendo uma boa performance nos testes realizados por López de Prado.

Jansen (2020) enfatiza que a seleção de um modelo adequado para o problema alvo é de extrema importância, visto que a escolha inadequada pode resultar em interpretações erradas dos dados, levando a previsões falhas e, conseqüentemente, a decisões de investimento prejudiciais. Além disso, Jansen (2020) discute que modelos como *Random Forest* e *Gradient Boosting* são recomendados em cenários de alta volatilidade devido à sua habilidade em modelar complexas interações entre variáveis, o que permite uma captura mais eficaz dos padrões subjacentes nos dados.

Diferentes tipos de modelos preditivos oferecem distintas vantagens para os *traders*, dependendo das características específicas dos dados e do ambiente de mercado. Modelos de *boosting*, por exemplo, adaptam-se eficientemente a mudanças de mercado, mostrando-se particularmente úteis em mercados com alta volatilidade. Jansen (2020) enfatiza que a capacidade desses modelos de ajustar-se continuamente aos novos dados torna-os ferramentas poderosas na geração de estratégias de negociação adaptativas.

A seleção de modelos adequados em negociação algorítmica deve ser metódica, priorizando critérios como precisão, robustez, generalização e velocidade de processamento. Como consequência desses requisitos, Jansen (2020) menciona a importância dos modelos *ensemble*, modelos que combinam as previsões de vários modelos menores, que melhoram significativamente a precisão das previsões e proporcionam uma proteção robusta contra o *overfitting* (quando um modelo descreve ruído em vez de sinal correto), que como complementado por Hilpisch (2020, p. 123)

O modelo pode ter bom desempenho nos dados nos quais foi testado, mas pouco ou nenhum poder preditivo em novos dados no futuro. *Overfitting* pode ser descrito como encontrar padrões que não se aplicam na realidade. Há um custo associado ao *overfitting* – uma estratégia que possui muito *overfitting* irá ter um desempenho inferior

no futuro.[FM2]

Dessa forma, utilizar os modelos ensemble exemplificados irão auxiliar com a entrada de alta frequência de dados e volatilidade do mercado, garantindo uma maior precisão de previsão e uma resposta mais rápida sobre novas informações do mercado.

Tratamento dos dados

Segundo Jurafsky (2023, p. 17) “antes de quase qualquer processamento de linguagem natural de um texto, o texto deve ser normalizado, uma tarefa chamada normalização de texto”. Dentro da normalização irão acontecer etapas como tokenização, padronização de formatos de palavras e segmentação de frases.

Após a normalização, existe outra etapa importante para o treinamento, a etapa de transformar os textos em valores numéricos que possibilitam a interpretação da máquina nos modelos de rede neural. Como comentado por JURAFSKY (2023), são utilizadas técnicas de vetorização e *embedding*, que transformam as palavras em números dentro de vetores, possibilitando analisar semelhança e recorrência das palavras, identificando contextos no texto.

Além disso, o uso de embeddings tem se destacado como uma técnica avançada para representar palavras em um espaço vetorial contínuo, capturando relações semânticas de forma mais precisa (JANSEN, 2020). *Embeddings*, como o Word2Vec, GloVe ou o mais recente BERT, mapeiam palavras com significados semelhantes para regiões próximas no espaço vetorial, permitindo que os modelos não apenas compreendam a frequência das palavras, mas também suas inter-relações contextuais. Essa técnica é fundamental para melhorar o desempenho de tarefas de PLN, como tradução automática, análise de sentimentos e reconhecimento de entidades, pois permite que o modelo lide melhor com nuances e ambiguidade linguística.

Machine Learning supervisionado no Mercado Financeiro

A técnica de *Machine Learning* envolve algoritmos que aprendem regras ou padrões através de dados para atingir um objetivo, como minimizar um erro de previsão (JANSEN, 2020). Como também comentado por Jansen, esses algoritmos muitas vezes são definidos por métodos estatísticos que podem prover uma percepção sobre o objeto de estudo e, com isso, é possível realizar uma análise futura sobre sua condição. Assim, quando aplicada a notícias e à condição do mercado, é esperado que uma aplicação de ML forme expectativas sobre o futuro e para que se possa decidir se é recomendado comprar ou vender ações ou

gerenciar os resultados do portfólio para produzir retornos relativos ao risco.

“O termo supervisionado implica a presença de uma variável de resultado que orienta o processo de aprendizagem” (JANSEN, 2020, pg. 149), ou seja, a base de dados deve ser rotulada para orientar o modelo em fazer a previsão mais adequada, o algoritmo mede sua precisão por meio de uma função de proporção de erro, ajustando-se até que o erro tenha sido suficientemente minimizado.

Análise de Sentimento e Processamento de Linguagem Natural em notícias

A explicação de mudanças nos preços das ações pode ser reforçada por meio das notícias geradas pelos veículos de mídia, que influenciam a maneira como os investidores abordam decisões arriscadas. O impacto coletivo desses estímulos é alterar o comportamento financeiro, criando padrões nos preços de mercado (PETERSON, 2016). Araci (2019) apresentou a importância da utilização de técnicas de processamento de linguagem natural (PLN) que facilitaram a análise de sentimentos e opiniões expressas em notícias e artigos financeiros. Esses sentimentos podem ser classificados como positivos, negativos ou neutros, impactando diretamente nas tendências das ações no mercado.

Para realizar a análise de sentimento é de suma importância escolher um modelo que se comporte bem em interpretação de contexto, e as redes neurais são apropriadas para essa resolução. “A rede neural é uma rede de pequenas unidades de computação, elas trabalham com vetores de valores e produzem um único valor de saída” (JURAFSKY, 2023, p.136). Ela é importante devido à sua capacidade de aprender com grandes volumes de dados em seus dados recebidos. O modelo é treinado com um banco de dados categorizado com base nos sentimentos das notícias, permitindo que o sistema aprenda e faça previsões precisas, além disso, redes neurais possuem a facilidade em adaptar-se a novos padrões de dados conforme incorporados ao treinamento, como também mencionado por Jurafsky (2023).

Método

Coleta dos Valores das Ações

Inicialmente será utilizada a biblioteca *yfinance* - uma biblioteca Python que permite acesso direto às informações financeiras disponibilizadas pelo Yahoo Finance - para coletar dados de preços de abertura, fechamento, máxima, mínima e volume das ações listadas no S&P500 e na B3. O uso da biblioteca em questão é essencial para a fase inicial de testes de

treinamento e performance dos modelos, devido à sua vasta quantidade de ações e fácil utilização.

Coleta das Notícias

A coleta de notícias será feita de duas maneiras distintas: a coleta histórica e a coleta diária. A necessidade de obtermos um histórico vem do treinamento do modelo, para que possamos ensiná-lo com uma maior quantidade de dados.

A primeira abordagem pesquisada para a coleta de dados foi o uso de uma API (Interface de Programação de Aplicações). APIs são conjuntos de rotinas, protocolos e ferramentas que facilitam a construção de software e aplicativos, fornecendo blocos de construção que podem ser utilizados pelos programadores de maneira eficiente (TULACH, 2008). Após uma análise criteriosa de diversas opções disponíveis no mercado, levando em consideração tanto o custo quanto a qualidade das informações, a API do Google News foi selecionada. Essa API oferece dados completos, incluindo a data, o título da notícia, uma breve descrição e a URL da fonte original, facilitando o tratamento e a análise de sentimento dessas notícias.

Para a coleta de dados históricos, foi desenvolvido um script em Python que realiza consultas automatizadas à API do Google News, abrangendo um intervalo de datas específico. Esse método permite o acesso contínuo a informações diárias de notícias dentro do período selecionado e será importante para realizar os *backtests*, “*uma simulação histórica de como uma estratégia seria tenha sido executado caso tenha sido executado durante um período anterior*” (López DE PRADO, 2020, p.151). Os dados obtidos são essenciais para o treinamento do modelo de machine learning, proporcionando uma base de dados ampla e diversificada para o processo de aprendizagem.

Tratamento dos dados e análise de sentimento por meio de técnicas de PLN

Para garantir a eficácia dos modelos de *machine learning*, é essencial realizar um tratamento adequado dos dados. Para Bishop (2006, p.3) “cuidados devem ser tomados durante o pré-processamento porque muitas vezes as informações são descartadas, e se essas informações são importantes para a solução do problema, a precisão geral do sistema pode ser prejudicada.” Com isso, foram criadas algumas das etapas que fazem esse tratamento, incluindo a padronização dos dados, tokenização e vetorização.

A padronização envolve a transformação dos dados para que todas as variáveis tenham média zero e desvio padrão unitário. Este passo é importante para garantir que

nenhuma variável domine o modelo devido à sua escala. Autores como López de Prado (2018), Bishop (2006), Jansen (2020) e Guida (2019) dão ênfase à padronização em seus artigos e livros.

Para o processo de padronização nós utilizamos as seguintes técnicas, mostrando-as com um exemplo da seguinte notícia: “Ações da Petrobrás despencam após demissão de Prates” (g1, 2024)

Ação	Resultado
Conversão para letras minúsculas	ações da petrobrás despencam após demissão de prates”
Remoção de pontuação, acentos e espaços extras	acoes da petrobras despencam apos demissao de prates
Remoção de “stopwords” (preposições, artigos e conjunções)	acoes petrobras despencam demissao prates
Lematização (Redução das palavras para suas raízes):	acao petrobras despencar demitir prates

Segundo Guida (2019), o processo de tokenização realiza a divisão do texto padronizado em unidades chamadas “tokens”, localizando os limites das palavras, com o objetivo de facilitar a análise e o processamento do texto, pois permite trabalhar com essas unidades (“tokens”) de forma individual.

Ação	Resultado
Aplicar a tokenização na frase padronizada	acao petrobras despencar demitir prates
Criar lista de “tokens	['acao', 'petrobras', 'despencar', 'demitir', 'prates']

Após a tokenização, é comum aplicar a vetorização, que converte os “tokens” em vetores numéricos que os algoritmos de *machine learning* podem processar. Uma abordagem popular é o uso de modelos de TF-IDF (*Term Frequency-Inverse Document Frequency*), que atribuem pesos aos termos (palavras) com base na sua frequência e relevância no documento. Jansen (2020, p.451) para isso utiliza-se a classe *TfidfVectorizer* biblioteca *Sklearn* em python. Essa classe possui as ferramentas necessárias para aplicar a vetorização na lista de tokens e as funções que são chamadas a partir dela para fazer isso acontecer, chamada de *fit_transform*, que transforma a lista de tokens em uma lista de pontuação TF-IDF, calculada da seguinte forma:

- $TF \text{ (Term Frequency)} = \frac{\text{número de vezes que o token aparece na lista}}{\text{número total de tokens}}$
- $IDF \text{ (Inverse Document Frequency)}, \text{ para verificar a importância de um token observando todas as listas de tokens do contexto} = \log \left(\frac{\text{número de listas}}{\text{número de listas que contém o token}} \right)$

O cálculo final se dá pela multiplicação de TF e IDF.

Portanto, para o exemplo ['acao', 'petrobras', 'despencar', 'demitir', 'prates'] tem-se:

- Cada termo aparece uma única vez e existem cinco termos no total para apenas uma lista como entrada, recebe-se:

$$[1/5, 1/5, 1/5, 1/5, 1/5] = [0.2, 0.2, 0.2, 0.2, 0.2]$$

- Aplicando os pesos de cada palavra, tem-se:

$$[0.2 * 1, 0.2 * 2, 0.2 * 3, 0.2 * 2, 0.2 * 1] = [0.2, 0.4, 0.6, 0.4, 0.2]$$

Esse valor seria a pontuação de cada “token”, porém, para esse valor ser utilizado em um contexto de modelo de “*machine learning*” é necessário aplicar uma normalização para que todas as notícias possuam a mesma magnitude no momento de serem analisadas.

A normalização que é aplicada nos cálculos de TF-IDF é a L2, que faz com que o vetor tenha o comprimento de 1, ela é definida por:

$$\frac{1}{\sqrt{v^2}}, \text{ onde } v \text{ são as pontuações dos tokens}$$

Aplicando essa normalização nos nossos dados tem-se:

$$[0.2294, 0.4588, 0.6882, 0.4588, 0.2294]$$

Esse é o valor final que será enviado para o modelo.

Após o pré-processamento, realizamos o *fine-tuning* em um modelo de Linguagem de

Grande Escala (LLM) por meio da biblioteca Hugging Face. Esse ajuste permite adaptar o modelo a tarefas específicas, como análise de sentimento, aproveitando seu pré-treinamento em uma vasta quantidade de dados. Denis Rothman (2024) descreve como o modelo BERT, por exemplo, pode ser refinado para tarefas específicas após o pré-treinamento, utilizando uma base ampla de conhecimento linguístico, ajustada por meio do *fine-tuning* para obter resultados otimizados para a análise de sentimentos e outras tarefas. Esse processo envolve configurar e carregar o modelo pré-treinado, preparar os dados de entrada com o BERT *tokenizer* e máscaras de atenção, dividir o conjunto de dados em partes de treino e validação e definir os hiperparâmetros para o loop de treinamento. Com isso, através da biblioteca Hugging Face, esse ajuste fino permite ao modelo captar nuances contextuais específicas da tarefa de análise de sentimentos, maximizando a precisão dos resultados. O processo de *fine-tuning* aproveita as vantagens do pré-treinamento, onde o modelo já possui uma compreensão ampla da linguagem, e o refina para identificar padrões e emoções presentes em novos dados, ajustando-se aos contextos fornecidos.


Modelo de previsão dos valores das Ações

Para a previsão de valores das ações, serão utilizados modelos de aprendizado de máquina, que se mostram eficazes na análise de séries temporais e na previsão de tendências de mercado. Para o desenvolvimento do projeto, são escolhidos modelos de aprendizado supervisionado de regressão como Regressão Linear, que como comentado por Jansen (2020), é um modelo que define uma relação entre uma variável de resultado contínua e variáveis de entrada de qualquer tipo, que passaram por um pré-processamento. Isso significa que o ML realiza uma conta de regressão linear, que quando aplica o “x” (valor de entrada) em uma função, ele consegue prever o “y” (valor previsto) respectivo daquele valor.

Também será utilizado outro modelo *Random Forest* para problemas de regressão. De acordo com Jansen (2020), as *Random Forest*, ou árvores de decisão randômicas são importantes pela sua transparência, interoperabilidade e caráter de generalização durante a construção de suas árvores individuais para evitar problemas de *overfitting*. [FM3]

A figura 3 apresenta um exemplo da construção de uma árvore do modelo em questão, no qual o algoritmo separa os dados de entrada do modelo (*features*) em modelos de decisão diferentes e no final faz uma média de qual resultado apareceu mais em suas folhas (*leafs*).

Figura 3 - Exemplo de uma *Random Forest*.



Fonte: Jansen, 2020, p.175

Os modelos foram selecionados por sua capacidade de capturar relações lineares e não lineares em dados financeiros.

O pré-processamento dos dados da YFinance será fundamental para a garantia de qualidade das previsões. Os dados serão tratados nesta etapa para eliminar valores discrepantes que não são úteis para o aprendizado, como mencionado pela afirmação “Condições de funcionamento anormais tendem a gerar degradação significativa do desempenho do resultado” (HODGE, 2004, p.86). Isso assegura que os modelos de aprendizado de máquina não sejam influenciados por valores inesperados, permitindo que aprendam padrões consistentes a partir dos dados. Após o pré-processamento, os dados serão divididos em conjuntos para treinamento, teste e validação. Os modelos serão ajustados com o conjunto de treinamento e a validação será usada com intuito de afinar os hiperparâmetros.


Como está-se lidando com dados de série temporal, ou seja, cada valor possui a característica de uma data relacionada, não se pode utilizar uma separação comum do conjunto de dado em treino e teste, isso porque “Cria-se uma situação em que dados do futuro seriam usados para prever dados do passado” (JANSEN, 2020, p. 168).

Para se lidar corretamente com séries temporais, Jansen (2020) reforça o fato de ser extremamente importante levar em consideração componentes como tendência de mercado, sazonalidade e ciclos com ruído sistemático, que influenciam em larga escala se um ativo irá subir ou descer. Para realizar a análise, Jansen constrói o seguinte pensamento e utiliza a biblioteca python *Statsmodels*:

Esses componentes podem ser modelados como combinação linear. 'Statsmodels' inclui um método simples para dividir a série temporal em tendências, sazonalidades e ruído sistemático usando médias móveis. Podemos aplicá-lo a dados mensais sobre indústrias manufatura que contém um forte componente de tendência e um componente de sazonalidade (JANSEN, 2020, p. 257)

A Figura 4 apresenta os gráficos resultantes que mostram componentes mencionados anteriormente. O componente '*Trend*' implica o movimento geral da série ao longo do tempo. O componente '*Seasonal*' representa os padrões de repetição de ciclo que ocorrem em intervalos regulares, como variações mensais ou anuais. E o componente '*Residuals*' simboliza o que resta da série temporal após a remoção dos componentes '*Trend*' e '*Seasonal*', ou seja, demonstra flutuações aleatórias ou ruídos que não podem ser explicados pelos padrões de tendência e sazonalidade. Dessa forma, Jansen os considera como *White Noises*, ruídos que não possuem autocorrelação com nenhum outro dado da série.

Figura 4 - Decomposição de séries temporais em tendência, sazonalidade e resíduos



Fonte: Jansen, 2020, p.258

Dessa forma, para solucionar os problemas mencionados nas definições anteriores, pode-se utilizar o método de *Cross-Validation* (CV) específico para séries temporais, o *TimeSeriesSplit-skitlearn*, que como comentado por Jansen, implementa uma didática de realizar a separação dos dados levando o tempo em consideração. Essa didática se baseia na constante expansão dos dados de treino, em que os conjuntos de treinamento subsequentes são super conjuntos dos conjuntos anteriores, detalhando no exemplo a seguir:

Figura 5 - Exemplo do TimeSeriesSplit.

```
[0 1 2 3 4] [5]
[0 1 2 3 4 5] [6]
[0 1 2 3 4 5 6] [7]
[0 1 2 3 4 5 6 7] [8]
[0 1 2 3 4 5 6 7 8] [9]
```

Fonte: Jansen, 2020, p.169

No exemplo da figura 5 o ML utilizará o conjunto de treino [0 1 2 3 4] para tentar prever o conjunto de teste [5], como passo seguinte, o ML irá para os próximos conjuntos, e progressivamente realizará seu treinamento nesse formato de separação que evita o *overfitting*.

Agora, para a otimização dos hiperparâmetros, os modelos serão treinados usando métodos como Grid Search que segundo (JANSEN, 2020), é uma estratégia essencial para o treinamento de alta precisão. A ideia principal do Grid Search é separar dados em duas etapas. Isso é feito para que cada partição seja usada uma vez como conjunto de validação e o restante como conjunto de treinamento. Uma parte dos dados (amostra de treinamento) é usada para treinar o algoritmo e o restante (amostra de validação) é utilizada para estimar o desempenho preditivo do algoritmo. O Grid Search seleciona o algoritmo com o menor erro ou menor risco estimado.


Visando reforçar a avaliação, serão combinadas as métricas com análises de *backtesting*, que também são exploradas por Hilpisch (2020), em que ele define e discute a validação de estratégias de negociação algorítmica por meio do *backtesting* para garantir seu desempenho usando dados históricos. Ao combinar ambos, podemos avaliar a precisão das previsões e a capacidade dos modelos de capturar variabilidade nos dados.

Resultados

Conseguiu-se criar uma ferramenta web que auxilia investidores, sejam iniciantes, intermediários ou avançados, a tomar uma melhor decisão sobre alguma ação em específico. A ferramenta consegue juntar o melhor dos dois mundos com *machine learning* para prever o valor da ação no dia seguinte e o algoritmo de processamento de linguagem natural para identificação de sentimento, gerando uma gestão de risco eficiente para ter certeza da tendência do mercado nos próximos dias.

Abaixo temos o *front-end* do projeto, que faz a conexão usuário-programa. Uma

interface bem intuitiva que consegue abordar os principais desenvolvimentos do projeto, como o *backtesting* do modelo ao longo do tempo, representado pelo gráfico na direita, as notícias mais relevantes que geram mais impacto para identificar a tendência do mercado e um gráfico intuitivo para mostrar as *candles* diárias das ações, com informações de abertura, fechamento, maior preço e menor preço.



Modelo de previsão de valores das ações


Para a previsão de preços das ações, foram utilizados os modelos de Regressão Linear Simples e Random Forest Regressor, avaliados com foco em prever tendências de ações de empresas como Vale e Petrobras no Brasil, e Apple e Microsoft nos EUA, escolhidas por seu alto volume de negociação e interesse do mercado.

A Regressão Linear Simples mostrou-se eficaz para ajustes lineares e apresentou uma boa estabilidade entre treino e teste (R^2 em torno de 0.98 para alguns ativos no conjunto de teste). No entanto, sua simplicidade limitou a capacidade de capturar a volatilidade e as dinâmicas complexas do mercado, resultando em um retorno percentual modesto de 104,18% para a AAPL.

Por outro lado, o Random Forest Regressor teve um desempenho superior, aproveitando sua estrutura de múltiplas árvores de decisão para capturar padrões complexos, embora alguns sinais de overfitting tenham surgido devido à discrepância entre R^2 de treino e teste. Este modelo foi particularmente eficiente em prever a direção dos preços, permitindo maximizar retornos com uma estratégia de compra e venda baseada na tendência projetada.

Para a AAPL, a Random Forest gerou um saldo final de 140194,57 e um retorno de 1301,95%, sendo, portanto, selecionada como a abordagem ideal para este projeto.

A seguir, uma imagem apresenta o benchmark entre os modelos Random Forest e Regressão Linear, comparando seu desempenho com a estratégia de Buy and Hold.



Modelo de Análise de Sentimento

Para identificar e classificar sentimentos em textos financeiros e apoiar decisões de investimento, foi utilizado o modelo DeBERTa V3-small, ajustado especificamente para análise de sentimentos em português e inglês. Essa versão avançada de BERT e RoBERTa combina uma estrutura de atenção desmembrada e um decodificador de máscara sofisticado, maximizando a precisão em tarefas de processamento de linguagem natural. Com seis camadas e 98 milhões de parâmetros, o modelo é otimizado para captar nuances e complexidades semânticas em textos financeiros, diferenciando sentimentos e emoções de forma precisa em ambos os idiomas.

O processo de tokenização foi crucial para converter os textos financeiros em sequências de tokens, preservando o contexto e as informações essenciais para a análise de sentimentos. Essa etapa garantiu que o modelo fosse capaz de diferenciar nuances emocionais e contextuais, otimizando a identificação de sentimentos específicos de conteúdos voltados para o mercado financeiro.

Para acelerar o treinamento e ajuste do modelo, foi utilizada a plataforma CUDA, que permitiu o processamento paralelo em GPUs. Com suporte para precisão mista (fp16), o processo de fine-tuning foi significativamente mais rápido, com desempenho elevado e

menor risco de overfitting. Esse ajuste permitiu que o modelo processasse grandes volumes de dados financeiros em tempo reduzido, aprimorando a identificação de sentimentos complexos em notícias financeiras.

A avaliação do modelo em um conjunto de testes demonstrou sua eficácia, com um eval_loss final de 0.032 e acurácia acima de 90% para textos com sentimentos claros. Esse desempenho destaca a capacidade do DeBERTa V3 em capturar a carga emocional de textos financeiros, apesar de apresentar alguns desafios em textos neutros ou ambíguos, onde os indicadores emocionais são menos evidentes.

A aplicação do modelo trouxe uma camada de insights valiosa para estratégias de investimento, complementando a análise técnica e a previsão de preços. Essa abordagem permite decisões mais informadas, com um risco reduzido em comparação com estratégias que se baseiam apenas na análise de preços

Para ilustrar a capacidade do modelo, abaixo estão alguns exemplos de textos financeiros (resumidos) e suas respectivas classificações de sentimento, variando entre negativo, neutro e positivo:

Texto	Sentimento
No último trimestre, as vendas da Componenta dobraram para EUR 131 milhões, enquanto o lucro zerou.	2 (Positivo)
O lucro operacional aumentou para EUR 13,1 milhões, de EUR 8,7 milhões, representando 7,7% das vendas.	2 (Positivo)
O prejuízo operacional totalizou EUR 4,0 milhões, comparado a um lucro de EUR 8,6 milhões.	0 (Negativo)
A empresa não tem planos de mover toda a produção para a Rússia, onde está crescendo.	1 (Neutro)

Junção dos Modelos: Previsão de Preços e Análise de Sentimento

Para otimizar a previsão de ações e capturar a complexidade do mercado financeiro, foi combinada a previsão de preços com o modelo Random Forest e a análise de sentimento com o modelo DeBERTa V3. Esta integração considera tanto a direção dos preços quanto o contexto de mercado, capturando a influência de notícias e eventos no sentimento geral.

O modelo de preços Random Forest fornece uma base técnica ao indicar a tendência de alta ou baixa. Entretanto, fatores externos, como notícias e eventos econômicos, podem influenciar rapidamente as expectativas do mercado. O modelo de análise de sentimento DeBERTa V3 entra como um moderador, ajustando o risco das operações conforme o sentimento do mercado. Quando a análise de sentimento indica otimismo em linha com a previsão de alta, a compra é intensificada; em cenários de incerteza, o volume da compra é reduzido. Da mesma forma, a venda é reforçada em tendência de queda acompanhada por um sentimento negativo, enquanto sentimentos ambíguos moderam a operação.

Foram realizados dois testes de backtesting para comparar o risco-retorno. O CustomStrategy (Integração dos Modelos), que integra a previsão de preços e a análise de sentimento, apresentou ganhos totais de \$25.493,63 com 49 decisões corretas em 55 trades, resultando em um drawdown máximo de apenas -0,75%. Essa estratégia combinada possibilitou uma abordagem mais cautelosa, onde a análise de sentimento ajuda a refinar o nível de exposição ao risco. Ao considerar o sentimento do mercado, a CustomStrategy permite uma reação mais rápida a mudanças emocionais, moderando o investimento em momentos de incerteza e reforçando operações seguras. Assim, embora o lucro total tenha sido ligeiramente inferior, o controle de risco e a consistência das operações foram significativamente melhores, com menos volatilidade e maior precisão.

Já o CustomStrategy2 (Apenas Previsão de Preços), que utiliza apenas a previsão de preços com o Random Forest, gerou ganhos ligeiramente superiores, totalizando \$26.670,29. Esta estratégia teve 38 decisões corretas em 47 trades e um drawdown maior, de -3,25%. Sem a análise de sentimento para moderar o risco, a CustomStrategy2 confia exclusivamente nas previsões de preços para operar, o que resulta em operações mais voláteis e expostas. Com menos ajustes baseados no contexto do mercado, essa abordagem oferece um potencial de ganho mais elevado, mas assume um risco maior, o que pode levar a perdas mais significativas em momentos de alta volatilidade.

No backtesting com ações da Apple, os resultados mostram que a CustomStrategy, apesar

de um lucro ligeiramente menor, apresentou um risco mais controlado, refletido no *drawdown* reduzido. A integração da análise de sentimento trouxe menos erros e operações mais consistentes, proporcionando um sistema de trading mais equilibrado entre segurança e retorno. Essa junção de modelos ofereceu controle aprimorado de risco e adaptação ao mercado, criando um sistema de trading algorítmico robusto que combina análise de preço e sentimento para alcançar um equilíbrio eficiente entre retorno e segurança.

Conclusão

Este estudo apresentou o desenvolvimento e implementação de um sistema de sugestão de investimentos que combina modelos de machine learning para previsão de preços e análise de sentimento para capturar tendências do mercado. O sistema integra a capacidade preditiva do modelo Random Forest com a análise de sentimentos via DeBERTa V3, proporcionando uma abordagem mais completa para a tomada de decisão.

Os resultados indicam que a integração dos dois modelos, embora não tenha melhorado especificamente a precisão das previsões de preços, trouxe uma melhoria significativa na relação retorno-risco das operações. A análise de sentimento, ao atuar como um moderador de risco, ajustou o volume das operações com base no sentimento de mercado, o que possibilitou um controle de risco mais eficiente e um *drawdown* mais baixo durante os testes de *backtesting*. Essa moderação reduziu a exposição a períodos de incerteza, elevando a consistência dos retornos.

Outro desafio importante identificado ao longo do desenvolvimento foi garantir a qualidade dos dados provenientes de notícias e realizar um pré-processamento eficaz. A diversidade de estilos e estruturas das notícias financeiras aumenta a complexidade do tratamento dos dados para análise de sentimento. A etapa de pré-processamento, incluindo limpeza, normalização e tokenização, é crucial para manter a integridade dos dados e evitar ruídos que possam comprometer a interpretação dos sentimentos. A padronização textual e a representação contextual através de *embeddings* foram essenciais para lidar com variações de linguagem, mas ainda apresentam limitações que podem afetar a robustez do modelo.

Assim, além de demonstrar uma estratégia eficaz para a gestão de risco em investimentos, este estudo contribui com uma abordagem inovadora para o uso de inteligência artificial e processamento de linguagem natural em finanças. Recomenda-se que pesquisas futuras explorem a aplicação deste sistema em diferentes contextos financeiros e testem novas técnicas de pré-processamento, buscando melhorar ainda mais o controle de

risco e a eficácia da análise de sentimentos em dados não estruturados.

Referências

- ARACI, D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models, 2019.
<https://arxiv.org/abs/1908.10063>
- AYELE A. Adapting CRISP-DM for Idea Mining : A Data Mining Process for Generating Ideas Using a Textual Dataset, 2020
- BISHOP, C. M. Pattern Recognition and Machine Learning. [s.l.] Springer, 2006.
- GU, S. et al. Empirical asset pricing via machine learning. Cambridge, Ma: National Bureau Of Economic Research, December, 2018.
- GUIDA, T. Big Data and Machine Learning in Quantitative Investment, 2019
- HILPISCH, Yves. Python for Algorithmic Trading: From Idea to Cloud Deployment. 1. ed. Sebastopol: O'Reilly Media, 2020.
- HODGE, V., e AUSTIN, J. A Survey of Outlier Detection Methodologies. Artificial Intelligence Review, Vol. 22, No. 2, pp. 85–126., 2004.
- HUGGING FACE. Modelo pré-treinado em dados financeiros da `mrm8488`. Disponível em <https://huggingface.co/mrm8488/deberta-v3-ft-financial-news-sentiment-analysis>. Acesso em 04/11/2024.
- JANSEN, S. Machine learning for algorithmic trading: predictive models to extract signals from market and alternative data for systematic trading strategies with Python. Birmingham; Mumbai: Packt Publishing, 2020.
- JURAFSKY, D., MARTIN, J. Speech and Language Processing, 2024.
https://web.stanford.edu/~jurafsky/slp3/ed3bookfeb3_2024.pdf
- LÓPEZ DE PRADO, M. Advances in financial machine learning. New Jersey: Wiley, 2018
- LÓPEZ DE PRADO, Beyond Econometrics: A Roadmap Towards Financial Machine Learning, 2019. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3365282
- LÓPEZ DE PRADO, M. M. Machine Learning for Asset Managers. [s.l.] Cambridge University Press, 2020.
- MITCHELL, R. Web Scraping com Python: Coletando Dados da Web Moderna. O'Reilly Media. 2018
- MITRA, G., D. DI BARTOLOMEO, A. BANERJEE AND X. YU, 'Automated Analysis of News

to Compute Market Sentiment: Its Impact on Liquidity and Trading,' UK Government Office for Science, 2015.

PETERSON, R. L. Trading on sentiment: the power of minds over markets. Hoboken, New Jersey: John Wiley & Sons, Inc, 2016.

ROTHMAN, D. Transformers for Natural Language Processing and Computer Vision, Packt Publishing. 2024

TULACH, J. Practical API Design. Apress. 2008.

TUNSTALL, L. Natural Language Processing with Transformers: Building Language Applications with Hugging Face. O'Reilly Media. 2022

WIRTH R. and HIPPE J., CRISP-DM: Towards a standard process model for data mining, 2000